

Deteksi *Face Anti-Spoofing* Berbasis Video Menggunakan *Central Difference Convolutional Networks*

St. Syakirah*

Fakultas Matematika dan Ilmu Pengetahuan
Alam
Magister Kecerdasan Artifisial
Universitas Gadjah Mada
Yogyakarta, Indonesia

Dhanar Januardhi Kusuma*

Fakultas Matematika dan Ilmu Pengetahuan
Alam
Magister Kecerdasan Artifisial
Universitas Gadjah Mada
Yogyakarta, Indonesia

Amar Ma'ruf*

Fakultas Matematika dan Ilmu Pengetahuan
Alam
Magister Kecerdasan Artifisial
Universitas Gadjah Mada
Yogyakarta, Indonesia

Anas Putra Agazy*

Fakultas Matematika dan Ilmu Pengetahuan Alam
Magister Kecerdasan Artifisial
Universitas Gadjah Mada
Yogyakarta, Indonesia

Lalu Muhamad Waisul Kurni*

Fakultas Matematika dan Ilmu Pengetahuan Alam
Magister Kecerdasan Artifisial
Universitas Gadjah Mada
Yogyakarta, Indonesia

Abstract – Sistem pengenalan wajah memiliki kerentanan terhadap serangan *spoofing* seperti penggunaan foto cetak, video replay, maupun tampilan wajah melalui layar digital. Oleh karena itu, diperlukan mekanisme *liveness detection* untuk memastikan bahwa wajah yang terdeteksi merupakan wajah asli manusia dan bukan hasil *spoofing* seperti foto, video replay, atau tampilan wajah melalui layar digital. Penelitian ini mengimplementasikan sistem *face liveness detection* menggunakan metode *Central Difference Convolutional Networks* (CDCN) untuk mendeteksi serangan *spoofing* berbasis citra RGB. Dataset yang digunakan diperoleh dari Kaggle dalam format video (.mp4) yang terdiri dari kategori real video dan attack video. Data video diproses melalui tahap *frame extraction* untuk menghasilkan citra wajah yang digunakan pada proses pelatihan model. Selanjutnya, sistem melakukan deteksi wajah dan ekstraksi area wajah sebelum dilakukan klasifikasi menggunakan model CDCN. Metode CDCN memanfaatkan operasi *central difference convolution* untuk meningkatkan kemampuan ekstraksi fitur tekstur lokal dan *pseudo-depth* wajah sehingga lebih efektif dalam membedakan wajah asli dan spoof. Sistem melakukan klasifikasi biner terhadap wajah yang terdeteksi menjadi kategori *live* atau *spoof*. Hasil implementasi menunjukkan bahwa metode CDCN mampu mendeteksi serangan *spoofing* berbasis video dan citra wajah dengan performa yang baik pada data pengujian. Penelitian ini menunjukkan bahwa pendekatan *face anti-spoofing* berbasis CDCN dapat digunakan untuk meningkatkan keamanan sistem autentikasi wajah menggunakan kamera RGB standar.

Kata Kunci — Deteksi *Liveness* Wajah, *Anti-Spoofing* Wajah, *Central Difference Convolutional Networks* (CDCN), *Deep Learning*, *Computer Vision*, *Video* RGB, Deteksi *Spoofing*

I. PENDAHULUAN

Perkembangan teknologi *face recognition* saat ini sudah banyak digunakan pada berbagai sistem autentikasi. Penggunaan teknologi ini dinilai praktis karena proses identifikasi dapat dilakukan hanya menggunakan wajah pengguna. Namun, sistem *face recognition* masih memiliki kelemahan terhadap *spoofing attack*, seperti penggunaan foto wajah, video replay, maupun tampilan wajah melalui layar digital. Serangan tersebut dapat menyebabkan sistem salah mengenali media palsu sebagai wajah asli sehingga keamanan sistem menjadi berkurang.

Untuk mengatasi permasalahan tersebut, diperlukan mekanisme *face liveness detection* atau *face anti-spoofing*. *Liveness detection* bertujuan untuk memastikan bahwa wajah yang terdeteksi merupakan wajah asli manusia dan bukan hasil *spoofing* seperti foto, video replay, atau tampilan wajah melalui layar digital. Dengan adanya *liveness detection*, sistem autentikasi wajah dapat menjadi lebih aman terhadap berbagai jenis *spoofing attack*.

Pada penelitian *face anti-spoofing*, metode berbasis deep learning banyak digunakan karena mampu melakukan ekstraksi fitur citra secara otomatis dan menghasilkan performa yang cukup baik. Salah satu metode yang digunakan pada penelitian ini adalah *Central Difference Convolutional Networks* (CDCN). Metode CDCN merupakan pengembangan dari *convolutional neural network* (CNN) yang dirancang agar lebih sensitif terhadap detail tekstur lokal pada wajah. Selain itu, CDCN juga memanfaatkan *pseudo-depth feature* untuk membantu membedakan wajah asli dan wajah spoof.

Pada penelitian ini dilakukan implementasi sistem *video-based face liveness detection* menggunakan metode CDCN. Dataset yang digunakan diperoleh dari Kaggle dalam format video

(.mp4) yang terdiri dari *real video* dan *attack video*. Data video kemudian diproses melalui tahap *frame extraction* untuk menghasilkan citra wajah yang digunakan pada proses pelatihan model. Selanjutnya dilakukan proses deteksi wajah, ekstraksi area wajah, dan klasifikasi menggunakan model CDCN untuk menentukan apakah wajah termasuk kategori *live* atau *spoof*.


Penelitian ini bertujuan untuk mengimplementasikan metode CDCN pada sistem *face liveness detection* berbasis video RGB serta mengetahui kemampuan model dalam membedakan wajah asli dan *spoof* berdasarkan fitur tekstur wajah. Diharapkan hasil penelitian ini dapat menjadi salah satu penerapan *computer vision* dan *deep learning* dalam meningkatkan keamanan sistem autentikasi berbasis wajah.

II. METODOLOGI

A. Dataset

Dataset yang digunakan pada penelitian ini diperoleh dari Kaggle dalam format video (.mp4). Dataset terdiri dari dua kategori utama yaitu *real video* dan *attack video*. *Real video* merupakan video wajah asli manusia, sedangkan *attack video* merupakan *video spoofing* yang digunakan untuk mensimulasikan serangan terhadap sistem autentikasi wajah.

Dataset dibagi menjadi data training sebesar 70%, data validation sebesar 15%, dan data test sebesar 15%. Untuk detail distribusi kelas, dan distribusi data bisa dilihat di **Gambar 1**.



Gambar 1. distribusi kelas dalam dataset, dan *split* data.

B. Pra-pemrosesan

Tahap preprocessing dilakukan sebelum data dimasukkan ke dalam model. Tahapan preprocessing yang dilakukan meliputi:

Frame extraction dari video dengan mengambil gambar dari *frame video* pada kelipatan *interval* 8 dan maksimal *frame* 25.

Resize citra menjadi ukuran 224×224 piksel.

Normalisasi ImageNet, nilai piksel 0-255 dinormalisasi menggunakan mean dan std ImageNet

Selain itu dilakukan data augmentation seperti horizontal flip, blur, dan penambahan noise untuk meningkatkan kemampuan generalisasi model.


C. Metode Central Difference Convolutional Networks

Metode yang digunakan pada penelitian ini adalah *Central Difference Convolutional Networks* (CDCN). CDCN merupakan pengembangan dari *convolutional neural network* (CNN) yang memanfaatkan *central difference convolution* untuk meningkatkan sensitivitas terhadap perubahan tekstur lokal pada citra wajah.

Berbeda dengan convolution biasa pada CNN konvensional, CDCN lebih fokus pada perbedaan antar piksel sehingga mampu mendeteksi *artifact* yang sering muncul pada spoofing attack seperti *texture layer*, *blur print*, dan *replay artifact*.

Model menghasilkan dua output utama yaitu klasifikasi *live/spoof* dan *pseudo-depth map* yang digunakan untuk membantu model mempelajari struktur wajah asli dan wajah spoof.

Arsitektur yang digunakan dapat dilihat di **Gambar 2**.



Gambar 2. arsitektur CDCN.

Proses pelatihan model dilakukan menggunakan *framework* PyTorch. Fungsi *loss* yang digunakan adalah *Binary Cross Entropy Loss* (BCE Loss) yang dikombinasikan dengan *depth supervision loss*.

Optimizer yang digunakan pada penelitian ini adalah *AdamW optimizer* dengan *learning rate* sebesar 0.0005. Penggunaan *AdamW* dipilih karena mampu memberikan proses optimisasi yang lebih stabil dibandingkan Adam biasa melalui mekanisme *weight decay* yang lebih baik untuk mengurangi *overfitting* selama proses training.

D. Baseline CNN

Sebagai pembanding, penelitian ini juga menggunakan *baseline convolutional neural network* (CNN) sederhana untuk melakukan klasifikasi *live* dan *spoof*. Arsitektur baseline terdiri dari beberapa *convolution layer*, *max pooling*, dan *fully connected layer* yang digunakan untuk klasifikasi biner. Untuk arsitektur dapat dilihat pada **Gambar 3**.

III. HASIL EKSPERIMEN

Eksperimen pada penelitian ini dilakukan menggunakan lingkungan Google Colaboratory dengan akselerasi GPU Tesla T4 yang memiliki kapasitas VRAM sebesar 15,6 GB. Framework utama yang digunakan adalah PyTorch versi 2.11.0 dengan dukungan CUDA, serta library pendukung OpenCV 4.13.0, NumPy 2.0.2, dan Scikit-learn untuk evaluasi metrik.

A. Konfigurasi dan Hasil Training

Fungsi *loss* yang digunakan adalah kombinasi *Binary Cross Entropy for classification loss* dan *Mean Squared Error* untuk *depth loss* dengan formula

$$L = (1-\alpha) \times L_{\text{BCE}} + \alpha \times L_{\text{MSE}}$$

dengan $\alpha=0,3$. *Optimizer* yang digunakan adalah AdamW dengan *learning rate* 5×10^{-4} dan *weight decay* 1×10^{-4} , dijadwalkan menggunakan *Cosine Annealing* dengan $T_{\text{max}}=30$. Training dijalankan dengan batch size 32 menggunakan *mixed precision training* dan *gradient clipping* dengan nilai maksimum 1,0. *Early stopping* dengan *patience*=8 epoch diimplementasikan berdasarkan nilai ACER validasi.


Proses *training* CDCN dihentikan pada epoch ke-17 dengan best checkpoint pada epoch ke-9 yang mencapai ACER validasi terbaik 5,00% dan AUC 0,9618, dengan akurasi training mencapai 98,18%. Proses *training* Baseline CNN dihentikan pada epoch ke-21 dengan *best checkpoint* pada epoch ke-13 yang mencapai ACER validasi terbaik 4,68%. Kurva *training* lengkap untuk kedua model yang menampilkan dinamika *loss*, *accuracy*, ACER, dan AUC sepanjang epoch ditunjukkan pada **Gambar 4**.



Gambar 4. kurva *training* CDCN vs Baseline CNN.

B. Evaluasi pada Test Set

Sebelum evaluasi pada *test set*, ambang batas dikalibrasi menggunakan *Youden's J Index* pada *validation set* dengan formula



Gambar 3. arsitektur *vanilla* CNN.

Baseline CNN digunakan untuk membandingkan performa model CDCN terhadap arsitektur CNN konvensional pada dataset yang sama.

E. Evaluasi

Selain menggunakan *threshold default* sebesar 0.5, penelitian ini juga melakukan kalibrasi *threshold* menggunakan metode Youden's J statistic pada validation set. Metode ini digunakan untuk mencari *threshold* optimal yang mampu menyeimbangkan true positive rate (TPR) dan false positive rate (FPR).

Threshold optimal diperoleh dengan:

$$J = TPR - FPR$$

Dimana TPR adalah *True Positive Rate* dan FPR adalah *False Positive Rate*. *Threshold* dengan nilai *Youden's J* tertinggi dipilih sebagai *threshold* optimal untuk proses klasifikasi *live* dan *spoof*. Penggunaan *validation set* pada tahap kalibrasi dilakukan untuk menghindari kebocoran informasi pada test set sehingga evaluasi akhir tetap bersifat objektif.

Kemudian untuk evaluasi model dilakukan menggunakan beberapa metrik performa yaitu *accuracy*, *Area Under Curve* (AUC), dan *Average Classification Error Rate* (ACER). *Accuracy* digunakan untuk mengukur persentase prediksi yang benar terhadap seluruh data pengujian.

AUC digunakan untuk mengukur kemampuan model dalam membedakan kelas *live* dan *spoof* berdasarkan probabilitas prediksi. Semakin tinggi nilai AUC, maka kemampuan diskriminasi model semakin baik.

Selain itu digunakan ACER sebagai metrik utama pada *face anti-spoofing*. ACER merupakan rata-rata error antara *Attack Presentation Classification Error Rate* (APCER) dan *Bona Fide Presentation Classification Error Rate* (BPCER). Semakin kecil nilai ACER, maka performa model dalam mendeteksi spoofing attack semakin baik.


$$\text{threshold} = \text{argmax}(\text{TPR} - \text{FPR})$$

untuk menghindari *data leakage*. Proses ini menghasilkan *threshold* optimal 0,6397 (TPR = 1,000 dan FPR = 0,087). Hasil evaluasi lengkap pada *test set* tercantum dalam **Tabel 1**. Model CDCN dengan *threshold* default 0,5 mencapai akurasi 86,20%, AUC 0,9293, APCER 17,33%, BPCER 10,20%, dan ACER 13,77%. Ketika menggunakan *threshold* optimal 0,6397, APCER turun menjadi 17,00% tetapi BPCER naik menjadi 11,22% sehingga ACER menjadi 14,11%. *Trade-off* ini wajar pada sistem klasifikasi biner, di mana *threshold* yang lebih tinggi membuat model lebih selektif dalam menyetujui akses, sehingga lebih banyak serangan tertolak namun risiko wajah asli ikut terblokir juga meningkat.

Metrics	CDCN (th r= 0.5)	CDCN (opt_thr = 0.64)	Baseline CNN
Accuracy(%)	86.20	85.86	91.08
AUC	0.9293	0.9293	0.9613
APCER(%)	17.33	17.00	12.00
BPCER(%)	10.20	11.22	5.78
ACER(%)	13.77	14.11	8.89

Tabel 1. hasil evaluasi *test set*

Di sisi lain, model Baseline CNN mencatat performa lebih tinggi dengan akurasi 91,08%, AUC 0,9613, APCER 12,00%, BPCER 5,78%, dan ACER 8,89%. Hasil ini dipengaruhi oleh ukuran dataset yang relatif kecil (160 video) dengan hanya satu jenis *replay attack*, sehingga kemampuan ekstraksi gradien CDCN belum optimal. Keunggulan CDCN dalam generalisasi lintas serangan biasanya baru terlihat pada dataset *benchmark* berskala besar seperti OULU-NPU atau SiW. Berdasarkan *confusion matrix* CDCN, dari 300 sampel *fake*, 249 diprediksi benar dan 51 salah (berkontribusi pada APCER), sementara dari 294 sampel *real*, 261 diprediksi benar dan 33 salah (berkontribusi pada BPCER). Hasil akhir menunjukkan kelas *fake* memiliki *precision* 0,88 dan *recall* 0,83, sedangkan kelas *real* memiliki *precision* 0,84 dan *recall* 0,89. F1-score yang seimbang sebesar 0,86 untuk kedua kelas membuktikan model tidak memiliki bias prediksi, dengan visualisasi performa lengkap disajikan pada **Gambar 5**.



Gambar 5. Evaluasi Komprehensif pada Test Set.


C. Ablation Study

Ablation study dilakukan untuk memvalidasi kontribusi komponen CDC dan mengkonfirmasi nilai θ optimal dengan memvariasikan θ dari 0,0 hingga 1,0, masing-masing dilatih selama 5 epoch dengan konfigurasi training yang identik. Hasil ablation study dirangkum pada **Tabel 2**.

θ	Mode	Accuracy (%)	ACER (%)	AUC
0.0	Vanilla CNN	86.49	13.60	0.9191
0.3	CDC	80.24	19.97	0.9358
0.5	CDC	86.82	13.25	0.9406
0.7	CDC	88.85	11.21	0.9549
1.0	Pure Gradient	88.01	11.85	0.9399

Tabel 2. hasil *ablation study* nilai θ

Sebagai titik referensi tanpa komponen gradien, nilai $\theta=0,0$ (setara *vanilla CNN*) menghasilkan ACER 13,60% dan AUC 0,9191. Kinerja terburuk dicatat oleh $\theta=0,3$ dengan ACER 19,97% karena proporsi gradien yang kecil justru mengganggu konvergensi komponen intensitas tanpa memberikan sinyal diskriminatif yang berarti pada 5 *epoch* pertama. Kenaikan performa mulai terlihat pada $\theta=0,5$ dengan ACER 13,25%, membuktikan manfaat nyata dari proporsi gradien yang setara. Konfigurasi optimal dicapai oleh $\theta=0,7$ dengan ACER terbaik 11,21% dan AUC tertinggi 0,9549, yang mengonfirmasi bahwa kombinasi 70% gradien dan 30% intensitas konsisten dengan rekomendasi paper Yu et al. (CVPR 2020). Sementara itu, $\theta=1,0$ (*pure gradient extractor*) menghasilkan ACER 11,85%; sedikit lebih rendah dari konfigurasi optimal, yang menunjukkan bahwa informasi intensitas piksel tetap memberikan kontribusi positif. Visualisasi lengkap dari *ablation study* ini disajikan pada **Gambar 6**.



Gambar 6. *ablation study* - pengaruh nilai θ .

Secara empiris, *ablation study* ini membuktikan tiga poin penting. Pertama, komponen CDC memberikan kontribusi nyata dalam meningkatkan performa model, ditunjukkan oleh penurunan ACER sebesar 2,39 persentase poin dari $\theta=0,0$ ke $\theta=0,7$. Kedua, nilai $\theta=0,7$ terbukti menjadi titik keseimbangan terbaik untuk mengkombinasikan informasi gradien dan intensitas. Ketiga, pemilihan nilai θ yang tidak tepat berdampak sangat fatal terhadap sistem keamanan ini; terdapat selisih ACER yang sangat substansial hingga 8,76 persentase poin antara konfigurasi terbaik ($\theta=0,7$) dan konfigurasi terburuk ($\theta=0,3$).

D. Inference Real-Time

Sistem inferensi *real-time* diimplementasikan untuk mendemonstrasikan penerapan praktis model CDCN menggunakan *webcam* dengan kecepatan rata-rata 5 FPS. Output sistem menampilkan label LIVE atau SPOOF beserta skor kepercayaan, visualisasi *bounding box* (hijau untuk wajah asli dan merah untuk serangan), serta *depth map* berukuran 110×80 piksel dengan *colormap* JET di pojok kanan bawah *frame*. Pada *depth map* tersebut, warna panas (merah/oranye) menunjukkan struktur tiga dimensi khas wajah asli, sedangkan warna dingin (biru) mengindikasikan permukaan datar dari serangan *spoofing*. Visualisasi ini memberikan interpretabilitas tambahan bagi operator sehingga keputusan model tidak sepenuhnya menjadi *black box*, dengan contoh *output* skenario wajah asli dan *replay attack* yang ditunjukkan pada **Gambar 7**.



Gambar 7. contoh output *inference real-time*.

IV. ANALISIS

A. Analisis Hasil

Berdasarkan hasil eksperimen, metode CDCN mampu melakukan klasifikasi *live* dan *spoof* dengan performa yang cukup baik pada dataset yang digunakan. Penggunaan *central difference convolution* membantu model untuk lebih sensitif terhadap perubahan tekstur lokal yang sering muncul pada *spoofing attack*.


B. Analisis Overfitting

Analisis *overfitting* dilakukan dengan membandingkan performa model pada *data training* dan *test set* menggunakan *best checkpoint* masing-masing model, dengan hasil dirangkum pada **Tabel 3**. Model CDCN pada epoch ke-9 mencapai akurasi training 98,18% namun hanya 85,86% pada *test set* dengan gap +12,32 persentase poin. Untuk ACER, nilai *training* 1,82% berbanding jauh dengan *test set* 14,11% menghasilkan gap +12,30 persentase poin, sedangkan AUC turun dari 0,9982 pada *training* menjadi 0,9293 pada *test set*. Berdasarkan kriteria evaluasi dimana gap di atas 10% dikategorikan sebagai *overfitting* serius, maka CDCN terindikasi mengalami *overfitting* yang memerlukan perhatian.

Metrics	CDCN Train	CDCN Test	Gap CDCN	Baseline Train	Baseline Test	Gap Baseline
Accuracy (%)	98.18	85.86	+12.32	96.37	91.08	+5.29
ACER (%)	1.82	14.11	+12.30	3.63	8.89	+5.26
AUC	0.9982	0.9293	-0.0689	0.9587	0.9613	+0.0026
Status	-	Overfit -ting	-	-	Mild Overfit	-

Tabel 3. hasil *overfitting training vs test*

Model *Baseline CNN* pada epoch ke-13 menunjukkan gap yang jauh lebih kecil dengan akurasi *training* 96,37% dibanding *test set* 91,08% menghasilkan gap +5,29 persentase poin, serta ACER *training* 3,63% dibanding *test set* 8,89% dengan gap +5,26 persentase poin. Kondisi ini dikategorikan sebagai *mild overfit* yang wajar untuk ukuran dataset kecil. Visualisasi perbandingan *training vs test* secara visual ditunjukkan pada **Gambar 8**.



Gambar 8. *overfitting analysis - training vs test gap*.

Overfitting yang lebih serius pada CDCN disebabkan oleh kapasitas model yang lebih besar dengan 5.059.266 parameter yang meningkatkan risiko hafalan terhadap pola spesifik

training ketika ukuran dataset tidak sebanding, serta sensitivitas komponen CDC terhadap karakteristik spesifik kamera dan kondisi akuisisi dalam *dataset training*. Untuk penelitian selanjutnya, strategi yang dapat diterapkan meliputi penambahan *data training* dari dataset yang lebih beragam, penerapan regularisasi yang lebih agresif, augmentasi yang lebih ekstensif seperti *mixup* atau *cutmix*, serta *cross-dataset testing* untuk mengukur kemampuan generalisasi yang sesungguhnya.

C. Analisis pengujian *realtime*

Pada pengujian *realtime*, model masih mengalami beberapa kesalahan klasifikasi terutama pada *spoof image* dengan kualitas tinggi. Hal ini menunjukkan bahwa metode berbasis RGB *camera* masih memiliki keterbatasan dalam membedakan wajah asli dan *spoof* dengan *artifact* yang sangat minim. Selain itu, performa inference juga dipengaruhi oleh pencahayaan, kualitas kamera, dan hasil *face cropping*.

V. KESIMPULAN

Penelitian ini berhasil mengimplementasikan sistem *face liveness detection* menggunakan metode *Central Difference Convolutional Networks* (CDCN). Sistem mampu melakukan klasifikasi wajah *live* dan *spoof* menggunakan dataset video RGB yang terdiri dari *real video* dan *attack video*.

Metode CDCN menunjukkan kemampuan yang cukup baik dalam mendeteksi *spoofing attack* melalui analisis fitur tekstur lokal dan *pseudo-depth feature*. Selain itu, implementasi *realtime* menggunakan *webcam* menunjukkan bahwa sistem dapat melakukan deteksi *live* dan *spoof* menggunakan kamera RGB standar. Namun, performa *realtime* masih dipengaruhi oleh faktor pencahayaan, kualitas kamera, posisi wajah, serta kualitas *face cropping* sehingga pada beberapa kondisi sistem masih mengalami kesalahan klasifikasi terhadap *spoof image* dengan kualitas tinggi.

Untuk pengembangan selanjutnya, penelitian dapat dikembangkan menggunakan dataset yang lebih kompleks dan beragam, metode *face detection* yang lebih robust, serta arsitektur *deep learning* yang lebih modern untuk meningkatkan performa dan stabilitas sistem *face anti-spoofing* pada kondisi *real-time*. Selain itu, penelitian selanjutnya juga dapat diarahkan untuk mendeteksi *spoofing* berbasis *generative AI* seperti *deepfake video* dan *AI-generated face* yang saat ini semakin berkembang dan berpotensi menjadi ancaman baru pada sistem autentikasi wajah berbasis kamera RGB.

REFERENSI

- [1] Z. Yu, X. Li, P. Wang, dan G. Zhao, "Searching Central Difference Convolutional Networks for Face Anti-Spoofing," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020, pp. 5295–5305.
- [2] I. Goodfellow, Y. Bengio, dan A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.
- [3] G. Bradski, "The OpenCV Library," *Dr. Dobb's Journal of Software Tools*, vol. 25, no. 11, pp. 120–126, 2000.
- [4] A. Paszke et al., "PyTorch: An Imperative Style, High-Performance Deep Learning Library," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2019, pp. 8024–8035.
- [5] N. Kose dan J.-L. Dugelay, "Classification of Printed and Displayed Faces Based on Image Blur and Specular Reflection," in *2013 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2013, pp. 1857–1861.
- [6] T. de Freitas Pereira, A. Anjos, J. M. De Martino, dan S. Marcel, "LBP-TOP Based Countermeasure Against Face Spoofing Attacks," in *Asian Conference on Computer Vision (ACCV)*, 2012, pp. 121–132.